


EgoAgentOS ResearchOps

证据门禁的多 Agent 具身科研基础设施



EgoAgentOS 作品简介

● 项目名称

EgoAgentOS ResearchOps

研究目标 → 可审计 Decision

● 问题与场景

具身 AI 实验仍散落在 SSH、脚本与聊天里。

目标、数据、运行、指标、结论彼此割裂

● 核心解决方案

1 Manager + 6 Worker，确定性控制面执法。

AgentTeams basis + EvidenceGate

● 创新与差异化

Planner ≠ Runner ≠ Evaluator ≠ Reviewer

Deterministic Core + LLM Residual

● 开放 / 复用价值

开放 7 Identity、6 Skill、4 MCP 与 replay fixtures。

VLA / World Model / 具身研究流水线

● 当前进展

本地 API、Web Cockpit、SQLite 与 judge replay 已运行。

23 API · 4 Web · 21 MCP + 2 bridge PASS


实验跑完，不等于结论可信

EgoAgentOS 把具身 AI 研发从“研究员 + SSH + 脚本”收束为可协作、可验证、可重放的生产线。




每一步都留下结构化状态、证据与责任边界

Research Goal → Experiment DAG → Execution → Evaluation → Independent Verification → Decision → Memory / Skill。



协作层可替换，确定性控制面不可绕过

本地 API / Web / SQLite 已运行；MCP repo HTTP loopback 与 API→GPU bridge 仅在 tests 验证；平台组件均未连接。



提案、执行、算分与签发必须分权

Research PI 管 Control Flow；6 个 Worker 管 Task Flow；所有命令先变成 typed artifact，再交给确定性控制面。

MATRIX ROOM

Research PI / Manager

冻结 Goal · 分解 DAG · 路由 Worker · 合并结构化结果

01 Scout

上下文

02 Architect

实验设计

03 Runtime

受控执行

04 Evaluator

确定性算分

05 Reviewer

独立复核

06 Memory Curator

验证后沉淀

责任链: Architect → Reviewer → Runtime → Evaluator → Reviewer → PI Decision

IDENTITY CONTRACT

边界先于能力

Research PI	路由 / 决策	不得改 raw metrics
Scout	检索 / 冻结	不得启动实验
Architect	hypothesis / DAG	不得自批计划
Runtime	typed MCP	不得任意 shell
Evaluator	metric / CI	不得改 checkpoint
Reviewer	反证 / gate	不得执行所审实验
Memory Curator	validated write	不得把猜测写成事实

Name · Role · Capabilities · Inputs/Outputs · Dependencies · Decision Boundary · Trace



共享引用: task_id · goal_digest · plan_digest · run_id · evidence_ids · trace_id

AgentTeams 未实连; default Web 无 HTTP MCP client; API→GPU bridge 仅由 tests 验证

聊天里的“同意”，不能启动一项 R2 实验

风险分类、action digest、scope、expiry、nonce 与 replay ledger 由代码执法；R2 / R3 必须停在人类 checkpoint。

RISK POLICY

R0 → R3

动作越昂贵或不可逆，授权越严格

R0Read only自动 + audit

R1Bounded mutation≤2 modeled GPU·h

R2Expensive runhuman approval

R3Critical actionapproval + rollback

NONo tokenfail closed

X1Used tokenrejected

bypass / expiry / scope mismatch / nonce replay → structured error + audit event

APPROVAL CONTRACT

一次批准只对应一次精确动作

requester	identity	谁提出
action_digest	SHA-256	绑定 config / budget / entrypoint
scope	task + generation	不能跨任务复用
expiry	≤15 minutes	过期即失效
nonce	single-use	原子消费
rollback_point	baseline plan pointer	仅记录指针；未执行回滚
audit	hash chain	每次决定可重放

共享 secret: API mint egoap1 → GPU MCP 单次接受 / replay 拒绝; UI fallback 不互通



状态与操作状态分离：task stage · run status · approval status · integration truth

已验证：无审批被拒绝；token replay 被拒绝；missing trace 停在 VERIFY

Skill 规定“怎么做”，MCP 限定“能调用什么”

6 个 versioned Skill 组织研究流程；4 个独立 MCP server 把 repo、dataset、GPU 与 metrics 收进 typed boundary。

SKILL MAP

6 个可复用能力

01ResearchPlan
goal.freeze · plan.validate

02Dataset Manifest
hash once · verify digest

03SafeRunner
allowlist · approval · idempotency

04Ablation Analyzer
paired delta · bootstrap CI

+ EvidenceGate / ResearchMemory; 所有包均含 I/O、trigger、failure、safety、version。

COMPOSITE CONTRACT

run_research_task@0.1.0

输入	ResearchGoal + ContextBundle + Budget + Policy
输出	RunManifest + MetricArtifact + Review + Decision
触发	Goal frozen · plan reviewed · action authorized
依赖	6 Skills · 4 MCP · evidence store · audit log
失败	MissingEvidence→PLAN; ApprovalDenied→BLOCKED; ToolError→typed retry
安全	no universal shell · trusted roots · exact-action token
验证	JSON Schema · digest closure · independent Reviewer
复用/版本	SemVer + package digest; validated memory → Skill candidate

fail-closed: LLM summary 不等于 metric; chat approval 不等于 authorization

MCP v2 · 4 SERVERS

7 typed tools

repo: snapshot / read_files
只读 trusted root

dataset: create / verify manifest
gpu: launch / status

当前状态21 PASS · repo HTTP loopback smoke

metrics_compare_paired

fixed-seed bootstrap · structured errors
GPU dry-run default · shell=False
仅 packaged synthetic_worker

+2 API→GPU MCP bridge PASS; default Web no HTTP client

先验证 ResearchOps 闭环，再连接真实实验室资源

SYNTHETIC：以下模型、GPU、资源与研究指标均为 fixtures；控制面、审批、证据、测试与 UI 为本仓库实际运行。

A · RESEARCH GOAL

一个窄而真实的研究问题

≥10 FPS

acceptance target

≤5%

MPJPE degradation

EgoLite

streaming perception

替换 heavy video representation；不把目标阈值写成真实结果。

B · EXPERIMENT PLAN

4 个对照臂，3 个 seeds

4 arms

LTX2B + 3 candidates

3 seeds

fixed split

24

modeled GPU·h

SYNTHETIC

no GPU host

Plan digest + budget + entrypoint 共同决定 R2；默认 dry-run。

C · POLICY

高成本执行先暂停

R2

human checkpoint

scope

task + generation

≤15 min

single-use token

未批准：执行入口保持 BLOCKED；批准不能跨 scope、过期或重放。

D · EVIDENCE GATE

结论必须绑定原始证据

7 / 7

required evidence

Reviewer

independent

KEEP


only after PASS

code · config · dataset manifest · log · metric · trace · review

JUDGE REPLAY · CHECKPOINT 1

R2 审批 先停住


Current gate = APPROVAL；R2 执行在 token 消费前保持 blocked。



JUDGE REPLAY · CHECKPOINT 2

7 / 7 后
才允许 KEEP

完成 13-stage replay; gate PASS、independent
Reviewer、decision 与 trace 绑定。



不是概念稿：API、Web、MCP transport 与 replay 都有当前证据

工作负载仍为 SYNTHETIC；下列 test counts、build 与 gate 行为来自本仓库当前运行。

A · BACKEND

FastAPI control plane

23 / 23

API/domain PASS

Ruff

PASS

MyPy

PASS

state · policy · approval · evidence · evaluator · persistence

B · FRONTEND

React Web Cockpit

4 / 4

Web tests PASS

Build

Vite PASS

0

console errors

UI

SYNTHETIC labeled

真实 approval / completed 截图来自运行中的 localhost:4173。

C · MCP

MCP v2 tool plane

21

MCP standalone PASS

2

API→GPU bridge PASS

23

make test-mcp PASS

4 servers / 7 tools · repo HTTP initialize/tools/list · default Web no MCP client

D · CLOSED LOOP

Judge replay

7 / 7

gate PASS

KEEP

decision

VALID

full event chain

approval consumed；bypass + replay blocked；missing-trace → VERIFY / no decision

系统不隐藏失败；它把失败变成可验证 procedure

资源曲线与模型结果均为 SYNTHETIC fixtures；恢复状态机、manifest 生成、证据记录与 memory gate 为真实代码路径。

A · OBSERVE

症状被记录

GPU low
synthetic signal

CPU high
hash saturation

data wait
startup bottleneck

Runtime 保留失败日志；原始 trace 不因重试被覆盖。

B · REVIEW

诊断不是聊天结论

SHA-256
repeated full hash

Reviewer
confirms evidence

PLAN
bounded recovery

No guess
must cite trace

Diagnosis: worker startup 反复全量 hashing，阻塞 data path。

C · RECOVER

恢复动作受控

Hash once
publish time

Verify
content digest

Replay
same digest

DatasetManifest 只在 trusted root 写固定 manifest；重放可验证。

D · MEMORY → SKILL

经验不能直接发布

1
validated success

Candidate
not published

Nacos
not configured

Trace → episodic memory → procedural memory → reviewed Skill candidate

本地闭环已经可运行；外部平台绝不靠 PPT 变成“已接通”

每个 adapter 只显示 not_configured / configured / reachable / verified；没有握手与负测，就不写 verified。

APACHE-2.0 CORE

开放：可重放的 Agent Infra

- 01 FastAPI + Web Cockpit
- 02 7 Agent Identity contracts
- 03 6 versioned Skill packages
- 04 4 MCP servers / 7 tools
- 05 EgoLite synthetic fixtures
- 06 tests · replay · docs · schemas

License · SECURITY · THIRD_PARTY · DATA/MODEL CARD 已包含

SOVEREIGN BOUNDARY

不开放：私有资产与权限

- 原始 ego / lab 数据不进入提交包
- 第三方权重遵循 upstream license
- API keys / secrets不提交；只用短期凭证
- 真实 GPU / scheduleroperator-owned adapter
- AgentTeams room消息不是 source of truth

字段权限、留存和费用随部署 profile 显式披露

INTEGRATION TRUTH

集成状态：逐项如实

- 已验证local API / Web / SQLite；repo HTTP + GPU bridge tests
- 未配置AgentTeams · Nacos · Higress · Aliyun SLS
- 未声称live GPU · real model gains
- 接口typed envelopes · health truth states
- 复赛真实 Matrix room + OTel export
- 决赛受控 scheduler / GPU adapter

维护：Schema / Skill / MCP 按 SemVer；deprecation 先告警，再迁移

已验证、已实现、待接入三层分开陈述

初赛提交一个能 replay 的 local product；复赛再用真实平台证据升级 integration state。

EVIDENCE LADDER

现在拥有什么

已运行

local control plane + Web Cockpit

FastAPI / SQLite / approval / evidence gate / trace / replay；实际页面与截图已核验。

已验证

23 API · 4 Web · 21 MCP + 2 bridge

R2 pause · 7/7 gate · KEEP；default Web 无 HTTP MCP client。

未配置

AgentTeams / Nacos / Higress / Aliyun / live GPU

仓库保留 adapter contracts 与 truth states；不把 contract 写成已集成。

SYNTHETIC: EgoLite workload、resource trace、model metrics 均非真实 GPU / dataset 实测。

DELIVERY PLAN

从初赛到决赛的验收梯子

08.09

Local replay locked

API · Web · Skills · tests · screenshots；MCP bridge = tests

现在

08.10-08.15

Submission package

PPT/PDF · summary · runbook · ZIP verification

初赛

复赛

Live AgentTeams room

typed envelopes · human intervention · room trace

下一阶段

复赛

Platform probes

Higress / Nacos / OTel · positive + negative tests

下一阶段

决赛

Controlled lab adapter

scheduler / GPU · real dataset · real metrics

目标

降级策略：外部平台不可用→local replay；GPU 不可用→synthetic fixture；所有状态保持 honest

我把具身研究经验压成一条可验证的 Agent Infra 生产线

吕新科 | 北京邮电大学 · 智能科学与技术

FOUNDER-PROBLEM FIT

为什么由我来做

01

具身 / VLA

ego→HaMeR/MANO→3D pose→VLA / 真机训练链路。

02

模型与实验

OpenTrackVLA、world-model、future feature 与 verifier harness。

03

Agent / 验证

Planner ≠ Executor ≠ Verifier；引用、反证、失败重试。

04

编译 / 系统

NaturalFlow compiler、Context DAG、SHA256 cache 与权限检测。

JUDGE REPLAY

请评委直接 replay，而不是相信我的 PPT

START

① 启动 local profile

make up · 打开 <http://localhost:4173>

PAUSE

② Reset → Run to next gate

观察 R2 停在 APPROVAL；尝试 bypass

VERIFY

③ Approve digest → Replay

检查 7/7 evidence、KEEP、trace 与 candidate Skill

附包：[docs/demo-runbook.md](#) · [docs/claims-evidence.md](#) · [tests/](#)

EgoAgentOS：让 Agent 不只是做实验，而是管理一条可信的 AI Research 生产线。