


GOAI 2026 复赛 | Agent Infra

EgoAgentOS

ResearchOps / RXP

让 Auto Research 从黑盒对话变成可签发、可验收、可重放的实验协议



P0 · 初赛反馈闭环

从 local synthetic 升级为 protocol + live-ready

● 01 · 协作证据

AgentTeams bridge

官方 *API contract · live service = SKIP*

● 02 · 数据底座

PostgreSQL profile

MVCC · RLS · immutable · LISTEN/NOTIFY

● 03 · 新协议

RXP/1 experiment grant

Intent → Grant → Receipt → Evidence → Decision

● 04 · 严格评测

14 adversarial scenarios

naive / core / target · independent oracle

● 05 · 评委复现

Cockpit + proof bundle

GitHub Pages 静态真相 · local full stack

● 06 · 事实边界

PASS / SKIP 分层

live GPU · AgentTeams · PolarDB PITR 不冒认

AI 会提实验，不等于实验可被相信

面向 AI / 具身研究工程师：把一次研究意图收束为完整矩阵、一次性权限、原始证据与独立 Decision 。




同一 run_id 贯穿完整实验闭环

AgentTeams 管动态协作；RXP 管实验事实；Skill / MCP 管受控动作；PostgreSQL 管持久状态。



RXP/1：一次授权与可验收因果链

它不替代 MCP / A2A / PROV / MLflow ；它补齐“谁可跑哪一格、该交什么证据、何时可下结论”。



冲突、超时与失败会改变路由

官方 Project API / Task / Artifact 语义通过 adapter 封装；同一 run 同时产出 AgentTeams trace 与 RXP closure refs 。

PROJECT ROOM

Research PI / Manager

创建 · Project · 分解 DAG · 委派 · 接受 · 验证 · 完成

01 Scout
冻结上下文

02 Architect
生成 MatrixPlan

03 Runtime
领取并执行

04 Evaluator
确定性算分

05 Reviewer
独立质疑

06 Memory
验证后沉淀

正常: delegate → accept → execute → verify | 异常: conflict → replan · timeout → reassign · crash → resume

OFFICIAL CONTRACT TRACE

每一步有观察断言

Create	Project API	必须返回 project_id
Decompose	Task DAG	依赖与 expected artifacts
Delegate	>=3 Workers	真实 worker principals
Accept	assignee state	不是 Manager 自演
Verify	Reviewer	与 Runtime 身份分离
Recover	replan / reassign	原因进入 trace
Finish	Decision	绑定 RXP ledger root

Trace contract : official delegation + artifact + spawn/tool result + independent review + persistent hash



共享：project_id · task_id · rxp_run_id · cell_id · trace_id · evidence_root

本地 contract tests 可验证; 未配置官方 live endpoint 时 target scenarios = SKIP，不能自证 PASS

同一 Agent 不得自评自证

至少 3 个真实 principal ； R2 / R3 必须停在人类 checkpoint ，恢复后仍沿用同一 correlation chain 。

PRINCIPAL MAP

>=3 distinct identities

权限边界先于模型能力

MG
R

Manager

route / merge

AR
C

Architect

plan · no approval

RU
N

Runtime

execute · no verdict

EV
A

Evaluator

metric · no artifact edit

RE
V

Reviewer

independent gate

HU
M

Human

R2/R3 grant

principal conflict / self-review / missing reviewer → structured error + no Decision

GRANT CONTRACT

一次批准只对应一次精确实验格

intent_digest	SHA-256	绑定 frozen objective
scope	run + cell	不能跨 matrix 复用
expiry	≤15 minutes	过期即失效
nonce	single-use	原子消费 / replay reject
receipt	run binding	执行事实反向绑定 Grant
rollback	checkpoint	恢复不覆盖原始失败
audit	hash chain	每次动作可重放

HMAC key 仅用于公开 fixture ； production signer / key custody 明确不在当前验证范围



HITL 不是 UI 按钮，而是可审计 state transition + scope-bound capability

负测：missing grant · scope mismatch · expired · replay · self-review · tamper 均 fail closed

discover → load → invoke → canary → rollback → retire

6 个 digest-pinned Skill package ； 3 个 allowlisted deterministic handler ； 每次调用输出 correlation trace 。

EXECUTABLE CORE

3 个可运行 handler

01
ResearchPlan
freeze · budget · falsifiability

02
Dataset Manifest
relative path · digest · canonical order

03
EvidenceGate
complete kinds · reviewer independence

04
SafeRunner
discoverable · generic invoke denied

+ AblationAnalyzer / ResearchMemory ； 高风险 runner 不因 registry 而绕过专用 approval path 。

RELEASE CONTRACT

skill://name@semver#package_digest

输入	typed payload + correlation_id + optional version pin
输出	result + input/output digest + invocation_id
发现	SKILL.md + project manifest · strict SemVer
路由	deterministic hash bucket · canary ≤50%
失败	E_VERSION_PIN · E_PACKAGE_DIGEST · E_NOT_EXECUTABLE
安全	handler allowlist · owner ≠ reviewer · fail closed
验证	same correlation + input → same invocation trace
生命周期	draft → canary → active → retired / rollback

当前 reference registry 为进程内状态； production lifecycle persistence 仍需接 control-plane store

RUNTIME PROOF

6 packages / 3 executable

discover : frontmatter + manifest
package digest 防静默替换

invoke : ResearchPlan / DatasetManifest / EvidenceGate
SafeRunner = E_NOT_EXECUTABLE

当前证据6 focused tests PASS

invocation trace

fixed-seed bootstrap · structured errors
GPU dry-run default · shell=False
仅 packaged synthetic_worker

复用：robotics / model training / data pipeline 共用合同；
handler 保持领域内确定性

实验 token 不是额度：它代表一次可审计、不可重放的实验授权

SYNTHETIC FIXTURE：签名 key 为公开 demo key；结构验证真实，production signature trust = NONE。

A · INTENT

冻结一个意图

1

intent digest

1

frozen policy

RXP/1

protocol version

目标、预算、接受阈值先 canonicalize；后续对象都反向引用。

B · MATRIX PLAN

展开完整矩阵

2 cells

baseline + candidate

2 / 2

COMPLETE

23

ledger entries

D3

evidence gate

MatrixLedger 证明 expected 与 observed 的集合闭合；漏一格不允许 Decision。

C · GRANT

人只批准精确 scope

R2

human checkpoint

scope

run + cell

≤15 min

single-use nonce

Grant 消费后产生 Receipt；重放、换 cell、改 payload、过期都被拒绝。

D · ACCEPTANCE

证据齐全才 Decision

7 / 7

evidence kinds

Reviewer

independent

DECIDED


only after PASS

Decision 绑定 evidence root、matrix root、reviewer 和所有 causal references。

JUDGE REPLAY · CHECKPOINT 1


一条 run
五个闭环对象

Intent → Grant → Receipt → Evidence → Decision ;
2 / 2 COMPLETE , 23-entry append-only ledger 。



故障注入 必须改变结局

timeout / conflict / replay / tamper 不能被吞掉：重路由、阻断或 SKIP 必须进入 evidence bundle。



同一仓库同时给出代码、负测、报告与 release gate

计数以最终验证报告为准；workload 仍为 SYNTHETIC，平台实连项单列 SKIP。

A · LOCAL TESTS

Core + protocol + Skills

PASS

API / RXP / Skill

Ruff

PASS

MyPy

PASS

最终全量 test count 在 evidence index 与 CI log 中冻结。

B · FRONTEND

React RXP Cockpit

11

Web tests PASS

Build

Vite PASS

0

console errors

UI

truth labels

1600×1000 与 390×844 已检查；RXP panel 首屏可见。

C · INTEGRATIONS

AgentTeams + PostgreSQL

LOCK

official API adapter

DOCKER

Postgres proof

SKIP

live platform

真实 Docker PostgreSQL 测试与官方 AgentTeams contract trace 分开陈述。

D · BENCHMARK

Strict corpus

14

attack scenarios

3

profiles

ORACLE

independent

dev gate 证明 local core；release gate 无 live target 时预期非零退出。

异常不是旁支：它必须改变 route、state 或 release verdict

每个 fault 都由 corpus 定义，adapter 输出受独立 oracle 与 schema-aware trace verifier 双重检查。

A · TIMEOUT

超时不伪装成功

deadline

subprocess timeout

cancel

structured

reassign

observable

worker 卡住 → timeout event → bounded reassign ；没有终态 trace 就不能 PASS 。

B · CONFLICT

并发冲突需显式解决

409

optimistic conflict

replan

generation++

hash

preserved

no overwrite

same run

两条并发链由事务 / expected_version 执法；旧 generation 不可静默覆盖新计划。

C · CRASH / RESUME

重启后不丢 causal chain

checkpoint

t

persist first

restart

fresh process

resume

same trace refs

SQLite local 与 PostgreSQL profile 都要求重启后读取 authoritative state 。

D · TAMPER / REPLAY

篡改与重放直接阻断

nonce

replay rejected

digest

tamper detected

Decision

withheld

错误本身进入 evidence bundle ；error / omission / timeout 都计入失败率。

协议不绑定某个模型；状态语义在 local 与 production profile 中保持一致

SQLite 用于离线 judge replay ； PostgreSQL 用于并发、租户、通知与不可变审计。真实 PolarDB 仍需部署证明。

RXP + AGENTTEAMS + SKILLS

可复用控制内核

01

Model training: arms × seeds

02

Data pipeline: source × transform

03

Robotics: policy × scene × seed

04

Eval: model × benchmark slice

05

Regulated workflow: maker/checker

06

AutoResearch: hypothesis queue

共同对象: Intent · Grant · Receipt · Evidence · Decision · MatrixLedger

PORTABLE RECIPES

场景只替换 schema / handler

领域 metric / evaluator

由 Skill handler 注入

资源 adapter

local / Slurm / K8s / cloud

证据 taxonomy

按合规场景扩展

人类权限线

R0-R3 policy 配置

结论规则

acceptance schema versioned

协议层不读取 secret ； 执行 adapter 只接短期凭证

INTEGRATION TRUTH

数据底座分级

已验证

SQLite local + Docker PostgreSQL tests

已实现

MVCC · RLS · immutable trigger · LISTEN/NOTIFY

未验证

PolarDB endpoint · PITR restore · cloud IAM

迁移

checksum migration + store contract

回退

external unavailable → local replay

目标

per-test schema + production backup drill

所有 profile 共用相同 state / idempotency / evidence invariants ； 差异只在 capability disclosure

每一条判断都能落到命令、文件、 artifact 或明确的 SKIP

Apache-2.0 核心 + schemas + fixtures + benchmark ；私有数据、密钥和真实 GPU 权限不进仓库。

EVIDENCE LADDER

现在拥有什么

已运行

local control plane + RXP cockpit

API / Web / RXP / Skill registry / strict benchmark ；静态页面不冒充后端调用。

已验证

Docker PostgreSQL + official-contract adapter tests

每项 evidence 与 same-run digest 对齐；负测与恢复分支保留。

仍为 SKIP

live AgentTeams · live GPU · PolarDB / PITR

没有 credentials / endpoint / same-run trace ，就不把设计写成集成成功。

SYNTHETIC：EgoLite workload、resource trace、model metrics；真实的是控制面、协议、测试与 UI。

REPRODUCTION PATH

复赛验收梯子

01

make test

unit / contract / negative controls / static checks

LOCAL

02

make demo-proof

ledger · matrix · benchmark · claim manifest

BUNDLE

03

target release gate

无 live target → non-zero / SKIP evidence

FAIL
CLOSED

04

operator live run

注入 credentials 后保存 official trace

EXTERNAL

05

freeze submission

PPT/PDF · demo · package · evidence index

SHA-256

GitHub Pages 仅托管 static judge replay；API / AgentTeams / PostgreSQL capability 必须由本地或部署 profile 证明

请直接复现，不必相信 PPT

吕新科 | 北京邮电大学 · 智能科学与技术

ONE RUN · ONE CLOSURE

演示节奏

01

0:00–1:00

痛点 + 初赛反馈：为什么需要 RXP。

02

1:00–3:00

AgentTeams 创建 / 委派 / 异常重路由。

03

3:00–5:00

R2 Grant → Receipt → 2/2 Matrix closure。

04

5:00–8:00

fault benchmark、PostgreSQL、SKIP boundary。

JUDGE REPLAY

评委复现：一个入口，四段证据

SEE

① 打开 static cockpit

确认 STATIC FIXTURE / NO API / NO GPU 标签

VERIFY

② 运行 local proof

make test · rxp demo / verify · benchmark dev gate

TRUST

③ 检查 release gate

无 live target 时必须失败；查看 persisted evidence bundle

附包：[docs/demo-runbook.md](#) · [submission/semifinal-evidence-index.md](#) · [benchmark artifacts](#)

EgoAgentOS / RXP：让 AI 不只会做实验，而是对实验的权限、完整性与结论负责。