


# EgoAgentOS

## ResearchOps / RXP

让 **Auto Research** 从黑盒对话变成可签发、可验收、可重放的实验协议



P0 · 复赛评委意见闭环

# 从 local proof 升级为 protocol + production-ready

## 01 · 协作证据

AgentTeams + bounded GPU chain

*bridge · recovery | official live NOT RUN*

## 02 · 数据底座

PostgreSQL control plane

*4 roles · RLS · append-only · LISTEN/NOTIFY*

## 03 · 新协议

RXP/1 experiment grant

*Intent → Grant → Receipt → Evidence → Decision*

## 04 · 严格评测

14 scenarios + 8 acceptance cases

*trace oracle · origin gate · recovery assertions*

## 05 · 评委复现

Cockpit + one-click acceptance bundle

*static replay · local full stack · frozen evidence*

## 06 · 事实边界

PASS / NOT RUN / UNVERIFIED

*official AgentTeams · GPU · PolarDB/PITR 不冒认*

# AI 会提实验，不等于实验可被相信

面向 AI / 具身研究工程师：把一次研究意图收束为完整矩阵、一次性权限、原始证据与独立 Decision 。




# 同一 run\_id 贯穿完整实验闭环

AgentTeams 管动态协作；RXP 管实验事实；Skill / MCP 管受控动作；PostgreSQL 管生产持久状态。



# RXP/1：一次授权与可验收因果链

它不替代 MCP / A2A / PROV / MLflow ；它补齐“谁可跑哪一格、该交什么证据、何时可下结论”。



# 冲突、超时与失败会改变路由

Bridge 将官方响应、typed Matrix、checkpoint、receipt 与 Decision 绑定同一 run，并可持久化到 PostgreSQL。

PROJECT ROOM

Research PI / Manager

创建 Project · 分解 DAG · 委派 · 接受 · 验证 · 完成

01 Scout  
冻结上下文

02 Architect  
生成 MatrixPlan

03 Runtime  
领取并执行

04 Evaluator  
确定性算分

05 Reviewer  
独立质疑

06 Memory candidate  
candidate only

正常：delegate → accept → execute → verify | 异常：conflict → replan · timeout → reassign · crash → resume

OFFICIAL CONTRACT TRACE

每一步有观察断言

|           |                   |                        |
|-----------|-------------------|------------------------|
| Create    | Project API       | 必须返回 project_id        |
| Decompose | Task DAG          | 依赖与 expected artifacts |
| Delegate  | >=3 Workers       | 真实 worker principals   |
| Accept    | assignee state    | 不是 Manager 自演          |
| Verify    | Reviewer          | 与 Runtime 身份分离         |
| Recover   | replan / reassign | 原因进入 trace             |
| Finish    | Decision          | 绑定 RXP ledger root     |

Trace contract : sequence + previous\_hash + event\_hash + typed lifecycle + independent review



共享：project\_id · task\_id · rxp\_run\_id · cell\_id · trace\_id · evidence\_root

bridge + PostgreSQL contracts 已验证；official service / Matrix / GPU 未实跑，target 必须 SKIP

# 同一 Agent 不得自评自证

至少 3 个真实 principal ； R2 / R3 必须停在人类 checkpoint ，恢复后仍沿用同一 correlation chain 。

PRINCIPAL MAP

>=3 distinct identities

权限边界先于模型能力

MG  
R

Manager

route / merge

AR  
C

Architect

plan · no approval

RU  
N

Runtime

execute · no verdict

EV  
A

Evaluator

metric · no artifact edit

RE  
V

Reviewer

independent gate

HU  
M

Human

R2/R3 grant

principal conflict / self-review / missing reviewer → structured error + no Decision

GRANT CONTRACT

一次批准只对应一次精确实验格

|               |             |                      |
|---------------|-------------|----------------------|
| intent_digest | SHA-256     | 绑定 frozen objective  |
| scope         | run + cell  | 不能跨 matrix 复用        |
| expiry        | ≤15 minutes | 过期即失效                |
| nonce         | single-use  | 原子消费 / replay reject |
| receipt       | run binding | 执行事实反向绑定 Grant       |
| rollback      | checkpoint  | 恢复不覆盖原始失败            |
| audit         | hash chain  | 每次动作可重放              |

HMAC key 仅用于公开 fixture ； production signer / key custody 明确不在当前验证范围



HITL 不是 UI 按钮，而是可审计 state transition + scope-bound capability

负测：missing grant · scope mismatch · expired · replay · self-review · tamper 均 fail closed

discover → load → invoke → canary → rollback → retire

6 个 digest-pinned Skill package ； 3 个 allowlisted deterministic handler ； 每次调用输出 correlation trace 。

EXECUTABLE CORE

3 个可运行 handler

01ResearchPlanfreeze · budget · falsifiability

02Dataset Manifestrelative path · digest · canonical order

03EvidenceGatecomplete kinds · reviewer independence

04SafeRunnerdiscoverable · generic invoke denied

+ AblationAnalyzer / ResearchMemory ； 高风险 runner 不因 registry 而绕过专用 approval path 。

RELEASE CONTRACT

skill://name@semver#package\_digest

输入typed payload + correlation\_id + optional version pin

输出result + input/output digest + invocation\_id

发现SKILL.md + project manifest · strict SemVer

路由deterministic hash bucket · canary ≤50%

失败E\_VERSION\_PIN · E\_PACKAGE\_DIGEST · E\_NOT\_EXECUTABLE

安全handler allowlist · owner ≠ reviewer · fail closed

验证same correlation + input → same invocation trace

生命周期draft → canary → active → retired / rollback

当前 reference registry 为进程内状态 ； production lifecycle persistence 仍需接 control-plane store

RUNTIME PROOF

6 packages / 3 executable

discover : frontmatter + manifest package digest 防静默替换

invoke : ResearchPlan / DatasetManifest / EvidenceGate SafeRunner = E\_NOT\_EXECUTABLE

当前证据6 focused tests PASS

invocation trace

fixed-seed bootstrap · structured errors  
GPU dry-run default · shell=False  
仅 packaged synthetic\_worker

复用 : robotics / model training / data pipeline 共用合同 ； handler 保持领域内确定性



# 实验 token 不是额度：它代表一次可审计、不可重放的实验授权

SYNTHETIC FIXTURE：签名 key 为公开 demo key；结构验证真实，production signature trust = NONE。

A · INTENT

冻结一个意图

1

intent digest

1

frozen policy

RXP/1

protocol version

目标、预算、接受阈值先 canonicalize；后续对象都反向引用。

B · MATRIX PLAN

展开完整矩阵

2 cells

baseline + candidate

2 / 2

COMPLETE

23

ledger entries

D3

evidence gate

MatrixLedger 证明 expected 与 observed 的集合闭合；漏一格不允许 Decision。

C · GRANT

人只批准精确 scope

R2

human checkpoint

scope

run + cell

≤15 min

single-use nonce

Grant 消费后产生 Receipt；重放、换 cell、改 payload、过期都被拒绝。

D · ACCEPTANCE

证据齐全才 Decision

7 / 7

evidence kinds

Reviewer

independent

DECIDED


only after PASS

Decision 绑定 evidence root、matrix root、reviewer 和所有 causal references。

JUDGE REPLAY · CHECKPOINT 1


一条 run  
五个闭环对象

Intent → Grant → Receipt → Evidence → Decision ;  
2 / 2 COMPLETE , 23-entry append-only ledger 。



# 故障注入 必须改变结局

timeout / conflict / replay / tamper 不能被吞掉：重路由、阻断或 **SKIP** 必须进入 **evidence bundle**。



# 同一仓库同时给出代码、负测、报告与 release gate

默认 209 tests 全过；另有 PostgreSQL 16.14 / 27 tests 。外部 live 项单列 NOT RUN 。

A · LOCAL TESTS

Core + protocol + Skills

209

default suite PASS

Ruff

PASS

MyPy

PASS

API 56 · RXP 26 · Skills 6 · Proof 1 · Benchmark 28  
Acceptance 16 · AgentTeams 28 · Experiments 13 · MCP 23 · Web 12

B · FRONTEND

React RXP Cockpit

12

Web tests PASS

Build

Vite PASS

0

console errors

UI

truth labels

1600×1000 与 390×844 已检查；新增 semifinal acceptance path 可切换。

C · INTEGRATIONS

AgentTeams + PostgreSQL

28

AgentTeams tests

27

PostgreSQL 16.14

NOT RUN

external live

bridge/trace 与本地 PG 实库通过；official AgentTeams 、GPU 、PolarDB 不在此结果中。

D · BENCHMARK

Strict corpus

14

attack scenarios

3

profiles

ORACLE

independent

dev gate 证明 local core ； release gate 无 live target 时预期非零退出。

# 异常不是旁支：它必须改变 route 、 state 或 release verdict

每个 **fault** 都由 **corpus** 定义，**adapter** 输出受独立 **oracle** 与 **schema-aware trace verifier** 双重检查。

A · TIMEOUT

超时不伪装成功

deadline  
subprocess timeout

cancel  
structured

reassign  
observable

worker 卡住 → timeout event → bounded reassign ；没有终态 trace 就不能 PASS 。

B · CONFLICT

并发冲突需显式解决

409  
optimistic conflict

replan  
generation++

hash  
preserved

no overwrite  
same run

两条并发链由事务 / expected\_version 执法；旧 generation 不可静默覆盖新计划。

C · CRASH / RESUME

重启后不丢 causal chain

checkpoint  
t  
persist first

restart  
fresh process

resume  
same trace refs

SQLite local 与 PostgreSQL profile 都要求重启后读取 authoritative state 。

D · TAMPER / REPLAY

篡改与重放直接阻断

nonce  
replay rejected

digest  
tamper detected

Decision  
withheld

错误本身进入 evidence bundle ； error / omission / timeout 都计入失败率。

# 协议不绑定某个模型；状态语义在 local 与 production profile 中保持一致

SQLite 仅作 dev fallback；PostgreSQL 是生产路径，承载并发、权限、通知与不可变账本。PolarDB 仍需云端实证。

RXP + AGENTTEAMS + SKILLS

可复用控制内核

01

Model training: arms × seeds

02

Data pipeline: source × transform

03

Robotics: policy × scene × seed

04

Eval: model × benchmark slice

05

Regulated workflow: maker/checker

06

AutoResearch: hypothesis queue

共同对象：Intent · Grant · Receipt · Evidence · Decision · MatrixLedger

PORTABLE RECIPES

场景只替换 schema / handler

领域 metric / evaluator

由 Skill handler 注入

资源 adapter

local / Slurm / K8s / cloud

证据 taxonomy

按合规场景扩展

人类权限线

R0-R3 policy 配置

结论规则

acceptance schema versioned

协议层不读取 secret；执行 adapter 只接短期凭证

INTEGRATION TRUTH

数据底座分级

已验证

PostgreSQL 16.14 · 27 integration tests

已实现

4 roles · RLS · append-only · LISTEN/NOTIFY

未验证

PolarDB · PITR · read/write split · cloud IAM

迁移

per-test schema · checksummed apply / verify

回退

explicit SQLite dev only · PG never silent fallback

目标

preflight PASS + restore / failover drill

所有 profile 共用相同 state / idempotency / evidence invariants；差异只在 capability disclosure

# 每一条判断都能落到命令、文件、 artifact 或明确的 NOT RUN

Apache-2.0 核心 + schemas + fixtures + benchmark ；私有数据、密钥和真实 GPU 权限不进仓库。

EVIDENCE LADDER

现在拥有什么

已运行

local control plane + RXP cockpit

API / Web / RXP / Skill registry / strict benchmark ；静态页面不冒充后端调用。

已验证

PostgreSQL 16.14 + AgentTeams bridge contracts

PG 27 + bridge 28 ；账本篡改、 receipt 重用、崩溃恢复与来源冒充均有负测。

仍为 SKIP

official AgentTeams · single GPU · PolarDB / PITR

没有可认证 origin、endpoint 与 same-run trace，就不把 contract 写成 live 成功。

SYNTHETIC：托管 EgoLite 指标；Fashion-MNIST adapter 已实现，但 live origin 仍 UNVERIFIED。

REPRODUCTION PATH

复赛验收梯子

01

make test

unit / contract / negative controls / static checks

LOCAL

02

demo-proof + acceptance

ledger · raw metrics · Matrix · trace · Decision

BUNDLE

03

target release gate

无 live target → non-zero / SKIP evidence

FAIL CLOSED

04

operator live bundle

官方 trace + raw metrics + origin attestation

EXTERNAL

05

freeze submission

PPT/PDF · demo · package · evidence index

SHA-256

GitHub Pages 仅托管 static judge replay ；API / AgentTeams / PostgreSQL capability 必须由本地或部署 profile 证明

# 请直接复现，不必相信 PPT

吕新科 | 北京邮电大学 · 智能科学与技术

ONE RUN · ONE CLOSURE

演示节奏

01

0:00-1:00

痛点 + 初赛反馈：为什么需要 RXP。

02

1:00-3:00

AgentTeams → 人工审批 → bounded single-GPU contract。

03

3:00-5:00

raw metrics → deterministic eval → reviewer → Decision。

04

5:00-8:00

PG roles / recovery、benchmark 与 NOT RUN boundary。

JUDGE REPLAY

评委复现：一个入口，三步复现

SEE

① 打开 static cockpit

确认 STATIC REPLAY / CONTRACT IMPLEMENTED / EXTERNAL NOT RUN

VERIFY

② 运行 local proof

make test · PostgreSQL 27 · acceptance bundle verify

TRUST

③ 检查 release gate

无可认证 origin 时禁止 live claim；检查 frozen acceptance bundle

附包：[judge-feedback-implementation.md](#) · [acceptance bundle](#) · [evidence index](#) · [benchmark artifacts](#)

EgoAgentOS / RXP：让 AI 不只会做实验，而是对实验的权限、完整性与结论负责。